

Exposé – Abschlussarbeit IKT-Master

Konzeption und prototypische Evaluation eines RAG-gestützten LLM-Tutors für Moodle-STACK-Aufgaben in mathematischen Grundlagenmodulen

Sidney Göhler

28. Juni 2026

Zusammenfassung

Die Arbeit untersucht die Gestaltung eines RAG-gestützten LLM-Tutors für STACK-Aufgaben in mathematischen Grundlagenmodulen. Während STACK weiterhin die mathematische Bewertung übernimmt, generiert ein externes LLM-Tutor-Interface auf Basis von Aufgabeninformationen, Studierendenantworten, Diagnosecodes und aufgabenspezifischen RAG-Kontexten adaptive didaktische Hinweise. Im Fokus steht die Frage, wie Prompt, Kontext und Modellwahl gestaltet werden müssen, damit Studierende beim Lösungsprozess unterstützt werden, ohne dass die vollständige Lösung unmittelbar vorgegeben wird. Die Arbeit umfasst die Entwicklung eines minimalen Prototyps sowie dessen technische und optional qualitativ-didaktische Evaluation mittels Think-Aloud-Methode.

Inhaltsverzeichnis

Inhaltsverzeichnis	2
1 Ausgangslage und Problemstellung	3
2 Forschungsfrage	5
3 Zielsetzung	6
4 Untersuchungsgegenstand und Eingrenzung	7
5 Methodisches Vorgehen	8
5.1 Analyse der Anforderungen	8
5.2 Auswahl und Modellierung einer Beispielaufgabe	9
5.3 Entwicklung des technischen Prototyps	9
5.4 RAG-Konzept	10
5.5 Prompt- und Tutor-Design	10
5.6 Evaluation	11
6 Erwartete Ergebnisse und wissenschaftlicher Beitrag	13
7 Quellenlage / aktueller Stand der Technik	14
7.1 Allgemeine KI-Chatbots mit mathematischen Fähigkeiten . . .	14
7.2 Mathematikspezifische Tutor- und Solver-Systeme	14
7.3 E-Assessment-Systeme mit mathematischer Bewertung	15
7.4 KI-gestützte Lernplattformen und Tutoresysteme	15
7.5 Einordnung in den aktuellen Stand der Forschung	15
7.6 Forschungslücke	16
8 Zeitplan	17
9 Vorläufige Gliederung	19

◀ 1 Ausgangslage und Problemstellung

Digitale Übungs- und Prüfungssysteme sind in mathematischen Grundlagenveranstaltungen an Hochschulen mittlerweile fest etabliert. Insbesondere digitale Aufgaben, die durch das Open-Source-E-Assessment-System **STACK** in Moodle ermöglicht werden, bieten eine symbolische Bewertung mathematischer Eingaben auf Basis des Computer-Algebra-Systems Maxima. Dadurch können nicht nur numerische Endergebnisse, sondern auch algebraisch äquivalente Ausdrücke erkannt und bewertet werden. Über sogenannte **Potential Response Trees** können zudem typische Fehlermuster identifiziert und mit spezifischem Feedback versehen werden.

Trotz dieser Stärken bleibt das Feedback in STACK-Aufgaben in der Regel statisch. Es muss vorab durch Lehrende formuliert werden und kann nur begrenzt flexibel auf individuelle Lösungswege, Ausdrucksweisen oder Verständnisschwierigkeiten reagieren. Gleichzeitig eröffnen aktuelle Large Language Models neue Möglichkeiten für adaptive, sprachlich differenzierte und dialogähnliche Lernunterstützung. LLMs können Erklärungen generieren, Rückfragen formulieren und Hinweise an den aktuellen Lernstand anpassen. Ihr Einsatz in mathematischen Lernumgebungen ist jedoch mit spezifischen Risiken verbunden. Dazu zählen insbesondere fachlich fehlerhafte Aussagen, unzuverlässige mathematische Bewertung und das direkte Ausgeben vollständiger Lösungen.

Die geplante Arbeit setzt an dieser Schnittstelle an. Die mathematische Bewertung soll weiterhin durch STACK erfolgen, während ein externer LLM-Tutor auf Basis der von STACK übergebenen Informationen didaktische Hinweise generiert. Der Tutor soll dabei ein **Retrieval-Augmented-Generation-Verfahren**, kurz RAG, nutzen. Über einen aufgabenspezifischen Kontext erhält das LLM relevante Informationen wie Aufgabentext, Lernziel, typische Fehler, didaktische Rahmenbedingungen, Hilfestufen und gegebenenfalls Musterlösungen. Im Zentrum steht nicht die Entwicklung eines vollumfänglichen Moodle-Plugins, sondern die prototypische Untersuchung eines minimalen Interfaces für einen klar eingegrenzten mathematischen Themenbereich.

Als Anwendungsdomäne wird die **Differentialrechnung**, insbesondere

◁ 1 Ausgangslage und Problemstellung

die Ableitung verketteter Exponentialfunktionen, gewählt. Eine beispielhafte STACK-Aufgabe lautet:

$$f(x) = -5e^{x^2-2e^x}.$$

Die korrekte Bearbeitung erfordert unter anderem die Anwendung der Kettenregel, die Ableitung des inneren Exponenten und die Berücksichtigung des konstanten Faktors. Typische Fehler, etwa das Vergessen der inneren Ableitung, können durch STACK diagnostiziert und an den LLM-Tutor übergeben werden.

◀ 2 Forschungsfrage

Die zentrale Forschungsfrage der Arbeit lautet:

Wie kann ein RAG-gestützter LLM-Tutor für Moodle-STACK-Aufgaben in mathematischen Grundlagenmodulen so gestaltet werden, dass er Studierende durch adaptive Hinweise unterstützt, ohne die vollständige Lösung vorzugeben?

Aus dieser übergeordneten Forschungsfrage ergeben sich folgende Teilfragen:

1. **Informationsübergabe und Systemarchitektur**
Welche Informationen müssen aus einer STACK-Aufgabe an ein externes LLM-Tutor-Interface übergeben werden, um aufgabenspezifische und fehlerbezogene Hilfestellungen generieren zu können?
2. **Prompt- und Kontextdesign**
Wie müssen Systemprompt, Aufgabenprompt, Tutor-Policy und RAG-Kontext strukturiert sein, damit ein LLM fachlich korrekte, verständliche und didaktisch angemessene Hinweise erzeugt?
3. **Vermeidung von Lösungsverrat**
Durch welche Strategien, insbesondere Hilfestufen, Kontextsteuerung und explizite Prompt-Regeln, lässt sich das Risiko reduzieren, dass das LLM die vollständige Lösung unmittelbar ausgibt?
4. **Modellauswahl**
Inwiefern eignet sich ein lokales LLM für diesen begrenzten mathematisch-didaktischen Anwendungsfall, und wie kann dessen Leistung gegebenenfalls mit einem kommerziellen Modell verglichen werden?
5. **Nutzbarkeit und didaktische Qualität**
Wie werden die generierten Hinweise von Studierenden hinsichtlich Verständlichkeit, Nützlichkeit und Unterstützung des Lösungsprozesses wahrgenommen?

◀ 3 Zielsetzung

Ziel der Arbeit ist die Konzeption, prototypische Implementierung und initiale Evaluation eines minimalen LLM-Tutor-Interfaces für ausgewählte STACK-Aufgaben aus einem gewählten Themenkomplex.

Der Prototyp soll eine Informationskette von STACK zu einem LLM-basierten Tutor realisieren. Dabei übernimmt STACK weiterhin die mathematische Bewertung, während der Tutor die didaktische Unterstützung leistet. Die zentrale Funktion des Prototyps besteht darin, auf Basis einer Aufgaben-ID, einer Studierendenantwort und optional eines Diagnosecodes einen geeigneten RAG-Kontext zu laden, daraus einen strukturierten Prompt zu erzeugen und einen adaptiven Hinweis durch ein LLM generieren zu lassen.

Konkret verfolgt die Arbeit folgende Ziele:

- Entwicklung eines technischen Interfaces zur Übergabe relevanter Informationen aus STACK an einen externen LLM-Tutor,
- Erstellung eines aufgabenspezifischen RAG-Kontexts für ausgewählte Ableitungsaufgaben,
- Entwicklung einer Tutor-Policy mit Hilfestufen zur Steuerung der didaktischen Unterstützung,
- systematische Gestaltung und Erprobung von Promptvarianten,
- Untersuchung von Strategien zur Vermeidung von Lösungsverrat,
- exemplarische Evaluation der erzeugten Tutorhinweise,
- Ableitung von Gestaltungsempfehlungen für LLM-basierte Tutorensysteme in STACK-Umgebungen.

Die Arbeit ist ausdrücklich als prototypische Untersuchung angelegt. Eine vollständige produktive Integration in Moodle, eine umfassende Rechteverwaltung oder eine groSS angelegte empirische Wirksamkeitsstudie sind nicht Gegenstand der Arbeit.

◀ 4 Untersuchungsgegenstand und Eingrenzung

Untersuchungsgegenstand ist ein RAG-gestützter LLM-Tutor für STACK-Aufgaben aus einem eng begrenzten mathematischen Themenfeld.

Die Eingrenzung erfolgt auf:

- mathematisches Thema: Differentialrechnung,
- Aufgabentyp: Ableitung verketteter Funktionen,
- Schwerpunkt: Kettenregel bei Exponentialfunktionen,
- technische Umsetzung: externes Tutor-Interface,
- didaktischer Fokus: adaptive Hinweise ohne direkte Lösungsvorgabe.

Nicht betrachtet werden:

- ein vollständiges Moodle-Plugin,
- eine allgemeine LLM-Tutoring-Plattform für beliebige mathematische Themen,
- eine automatische mathematische Bewertung durch das LLM,
- umfangreiche Learning-Analytics-Funktionen,
- eine groß angelegte quantitative Studie.

Diese Eingrenzung dient dazu, die Fragestellung präzise und empirisch bearbeitbar zu halten.

◀ 5 Methodisches Vorgehen

Die Arbeit folgt einem entwicklungsorientierten Forschungsansatz. Im Mittelpunkt steht die Gestaltung und Evaluation des LLM-Tutor-Prototyps. Methodisch lässt sich das Vorhaben als prototypische Softwareentwicklung mit anschließender qualitativer und technischer Evaluation beschreiben.

5.1 Analyse der Anforderungen

Zu Beginn werden die Anforderungen an den Tutor und die Informationsübergabe analysiert. Dabei werden insbesondere folgende Fragen betrachtet:

- Welche Informationen kann STACK über einen Feedback-Link bereitstellen?
- Welche Informationen benötigt das LLM, um eine hilfreiche Antwort zu erzeugen?
- Welche Informationen sollten dem LLM bewusst nicht oder erst auf höheren Hilfestufen bereitgestellt werden?
- Welche Fehlerarten treten bei der gewählten Aufgabenklasse typischerweise auf?
- Welche didaktischen Anforderungen gelten für hilfreiche, ohne die Lösung zu verraten?

Das Ergebnis dieser Phase ist ein Anforderungskatalog für den minimalen Prototyp.

◀ 5 Methodisches Vorgehen

5.2 Auswahl und Modellierung einer Beispielaufgabe

Als exemplarischer Aufgabentyp wird eine Ableitungsaufgabe zur Kettenregel gewählt, beispielsweise:

$$f(x) = -5e^{x^2-2e^x}.$$

Für diese Aufgabe werden typische Fehlermuster definiert, etwa:

- fehlende innere Ableitung,
- fehlerhafte Ableitung von e^x ,
- fehlerhafte Ableitung von x^2 ,
- vergessener konstanter Faktor,
- Vorzeichenfehler,
- Ableitung nur des inneren Exponenten.

Diese Fehlermuster werden in Diagnosecodes überführt, die durch STACK beziehungsweise die prototypische Schnittstelle an den Tutor übergeben werden können.

5.3 Entwicklung des technischen Prototyps

Der technische Prototyp realisiert die minimale Informationsübergabe:

$$\text{STACK} \rightarrow \text{Tutor-Interface} \rightarrow \text{LLM} \rightarrow \text{Tutor-Interface}.$$

Im Minimalprototyp erfolgt die Rückgabe nicht direkt in die STACK-Oberfläche, sondern über ein externes Tutor-Interface, das aus STACK heraus geöffnet wird. Eine tiefere Rückintegration in Moodle oder STACK kann als mögliche Weiterentwicklung diskutiert werden.

Der Prototyp soll mindestens folgende Funktionen bereitstellen:

- Entgegennahme einer Aufgaben-ID,
- Entgegennahme der Studierendenantwort,
- Entgegennahme eines optionalen Diagnosecodes,
- Laden eines passenden RAG-Kontexts,
- Erzeugung eines Prompts,
- Aufruf eines LLMs,
- Anzeige des generierten Hinweises.

◀ 5 Methodisches Vorgehen

5.4 RAG-Konzept

Das RAG-Verfahren wird bewusst kontrolliert und aufgabenspezifisch umgesetzt. Anstelle einer umfangreichen Vektordatenbank genügt im ersten Schritt ein dateibasiertes Retrieval. Über die aus STACK übergebene Aufgaben-ID wird ein zugehöriger Kontext geladen.

Dieser Kontext kann folgende Bestandteile enthalten:

- Aufgabentext,
- mathematisches Thema,
- Lernziel,
- relevante mathematische Regel,
- typische Fehler,
- Diagnosebeschreibungen,
- Tutor-Regeln,
- Hilfestufen,
- gegebenenfalls Musterlösung.

Ein zentraler Aspekt ist die Steuerung, welche Informationen dem LLM auf welcher Hilfestufe zur Verfügung gestellt werden. Insbesondere ist zu untersuchen, ob die Musterlösung bereits im Kontext enthalten sein sollte oder ob dies das Risiko von Lösungsverrat erhöht.

5.5 Prompt- und Tutor-Design

Ein Schwerpunkt der Arbeit liegt auf dem Entwurf geeigneter Prompts. Der Prompt soll das Modell klar als Tutor positionieren und ihm zugleich Grenzen setzen.

Zu berücksichtigen sind unter anderem:

- Rolle des Modells als Tutor,
- Verweis darauf, dass STACK die mathematische Bewertung übernommen hat,
- Beschreibung der Aufgabe,
- Studierendenantwort,
- Diagnosecode oder Fehlerbeschreibung,

◀ 5 Methodisches Vorgehen

- RAG-Kontext,
- Hilfestufe,
- erlaubte und verbotene Inhalte,
- maximale Antwortlänge,
- Aufforderung zu aktivierenden Rückfragen.

Beispielhafte Anforderungen an den Prompt sind:

- keine eigenständige Bewertung der Antwort durch das LLM,
- keine vollständige Lösung auf der ersten Hilfestufe,
- Bezug auf den konkreten Fehler,
- kurze und verständliche Formulierung,
- Förderung des nächsten Denk- oder Lösungsschritts,
- keine Befolgung potenzieller Anweisungen aus der Studierendenantwort.

Es können verschiedene Promptvarianten systematisch miteinander verglichen werden, etwa Prompts mit oder ohne Musterlösung, mit oder ohne Diagnosecode sowie mit unterschiedlichen Hilfestufen.

5.6 Evaluation

Die Evaluation besteht aus einer technischen und einer didaktisch-qualitativen Komponente.

Technische Evaluation

Die technische Evaluation prüft die Funktionsfähigkeit des Prototyps. Dabei werden unter anderem folgende Kriterien betrachtet:

- korrekte Übergabe der Informationen aus STACK,
- korrektes Laden des RAG-Kontexts,
- korrekte Prompt-Erzeugung,
- erfolgreiche Kommunikation mit dem LLM,
- korrekte Anzeige des Tutorhinweises,
- Stabilität des Prototyps bei typischen Eingaben,
- Antwortzeiten.

◀ 5 Methodisches Vorgehen

Didaktisch-qualitative Evaluation

Die didaktische Evaluation untersucht die Qualität der generierten Hinweise. Kriterien können sein:

- fachliche Korrektheit,
- Verständlichkeit,
- Bezug zur Studierendenantwort,
- Bezug zur Diagnose,
- Hilfreichkeit für den nächsten Lösungsschritt,
- Vermeidung von Lösungsverrat,
- Aktivierung der Lernenden durch Rückfragen.

Optional kann eine kleine Erprobung mit Studierenden durchgeführt werden. Hierfür eignet sich die **Think-Aloud-Methode**. Dabei bearbeiten Studierende eine STACK-Aufgabe, erhalten einen generierten Hinweis und verbalisieren währenddessen ihre Gedanken. Ergänzend kann ein kurzes Interview durchgeführt werden.

Mögliche Leitfragen sind:

- War der Hinweis verständlich?
- Hat der Hinweis geholfen, den Fehler zu erkennen?
- War der Hinweis zu allgemein, passend oder zu direkt?
- Wurde die Lösung vorweggenommen?
- Würde ein solcher Tutor beim Üben als hilfreich empfunden?

Die qualitative Evaluation dient nicht dem Nachweis einer allgemeinen Lernwirksamkeit, sondern der explorativen Einschätzung von Verständlichkeit, Nützlichkeit und didaktischer Angemessenheit des Tutor-Designs.

◀ 6 Erwartete Ergebnisse und wissenschaftlicher Beitrag

Als Ergebnis der Arbeit wird ein minimaler, funktionsfähiger Prototyp erwartet, der die Informationsübergabe von STACK zu einem RAG-gestützten LLM-Tutor realisiert. Zusätzlich sollen Prompt-Templates, ein aufgabenspezifischer RAG-Kontext und eine Tutor-Policy mit Hilfestufen entwickelt werden.

Der wissenschaftliche Beitrag liegt insbesondere in der systematischen Untersuchung des Tutor-Designs. Die Arbeit zeigt exemplarisch, wie ein symbolisch-mathematisches Bewertungssystem und ein generatives Sprachmodell sinnvoll kombiniert werden können, ohne die mathematische Bewertungsverantwortung an das LLM zu übertragen.

◀ 7 Quellenlage / aktueller Stand der Technik

Es existieren bereits verschiedene kommerzielle Systeme zur mathematischen Unterstützung, zum KI-gestützten Lernen und zum digitalen mathematischen Assessment. Diese lassen sich grob in vier Kategorien einteilen: allgemeine LLM basierte Chatbots mit mathematischen Fähigkeiten, mathematikspezifische Tutor- und Solver-Systeme, E-Assessment-Systeme mit mathematischer Bewertung sowie machine Learning-gestützte Lernplattformen.

7.1 Allgemeine LLM basierte Chatbots mit mathematischen Fähigkeiten

Zu den allgemeinen LLM basierte Chatbots zählen unter anderem *ChatGPT*, *Claude*, *Gemini*, *Microsoft Copilot* und *Perplexity*.

Diese Systeme können mathematische Aufgaben erklären, Lösungsschritte formulieren und dialogisch auf Rückfragen reagieren. Ihre Stärke liegt vor allem in der sprachlichen Flexibilität und der Fähigkeit, Erklärungen an unterschiedliche Formulierungen oder Nachfragen anzupassen.

Für den hier untersuchten Anwendungsfall sind diese Systeme jedoch nur eingeschränkt geeignet. Sie bewerten mathematische Eingaben nicht grundsätzlich zuverlässig, geben häufig vollständige Lösungen aus und verfügen nicht über eine direkte Anbindung an STACK oder dessen Potential Response Trees. Zudem ist ihr Einsatz häufig mit Datenschutzfragen verbunden, da die Verarbeitung meist über externe Cloud-Infrastrukturen erfolgt.

7.2 Mathematikspezifische Tutor- und Solver-Systeme

Eine zweite Gruppe bilden mathematikspezifische Systeme wie *Photomath*, *Symbolab*, *Mathway*, *WolframAlpha Pro* und *Microsoft Math Solver*. Diese Anwendungen sind auf die Lösung mathematischer Aufgaben spezialisiert und bieten häufig Schritt-für-Schritt-Lösungen an. Sie sind insbesondere bei Standardaufgaben in Algebra, Analysis und elementarer Mathematik leistungsfähig.

◀ 7 Quellenlage / aktueller Stand der Technik

Der Schwerpunkt dieser Systeme liegt jedoch überwiegend auf der Lösungserzeugung. Damit unterscheiden sie sich grundlegend von einem Tutoransatz, der Lernende gezielt zum nächsten Denkschritt führen soll, ohne die vollständige Lösung unmittelbar vorzugeben.

Eine Nutzung strukturierter STACK-Diagnosecodes oder eine didaktisch kontrollierte Hint-Policy ist in diesen Systemen in der Regel nicht vorgesehen.

7.3 E-Assessment-Systeme mit mathematischer Bewertung

Zu den kommerziellen oder produktiv eingesetzten E-Assessment-Systemen mit mathematischer Bewertung zählen unter anderem *Möbius* von Maplesoft, *ALEKS* von McGraw Hill, *MyMathLab* von Pearson, *Knewton Alta*, *WirisQuizzes* sowie nicht-kommerzielle bzw. offene Systeme wie *STACK* und *WeBWorK*. Diese Systeme ermöglichen die automatische Bewertung mathematischer Antworten, teilweise unter Nutzung symbolischer Mathematik oder adaptiver Aufgabensteuerung.

Für den geplanten Ansatz ist insbesondere relevant, dass diese Systeme zwar mathematische Bewertung und teilweise Feedbackmechanismen bereitstellen, jedoch nicht notwendigerweise adaptive LLM-basierte tutorielle Hinweise generieren. Das Feedback ist häufig regelbasiert, vorstrukturiert oder proprietär gesteuert. Eine explizite Verbindung von STACK-Diagnosecodes mit einem RAG-gestützten LLM-Tutor ist bislang nicht als etablierte Standardfunktion verfügbar.

7.4 Machine Learning gestützte Lernplattformen und Tutoriensysteme

Weitere relevante Systeme sind Machine Learning gestützte Lernplattformen und Tutoriensysteme wie *Khanmigo* von Khan Academy, *Carnegie Learning/MATHia*, *Squirrel AI*, *Querium* und vergleichbare adaptive Lernumgebungen. Diese Systeme verfolgen teilweise stärker tutorielle Ansätze und versuchen, Lernende durch Rückfragen und adaptive Unterstützung zu begleiten.

Insbesondere *Khanmigo* ist für den Vergleich relevant, da es darauf ausgelegt ist, Lernende nicht nur mit Lösungen zu versorgen, sondern durch dialogische Unterstützung zum eigenständigen Denken anzuregen. Dennoch handelt es sich nicht um eine STACK-spezifische Lösung.

Eine direkte Nutzung von Potential Response Trees, STACK-Diagnosecodes oder hochschulspezifischen Aufgabenmetadaten ist nicht Bestandteil dieser Systeme.

◀ 7 Quellenlage / aktueller Stand der Technik

7.5 Einordnung in den aktuellen Stand der Forschung

Nach aktuellem Stand der Forschung liegt die zentrale Herausforderung beim Einsatz von LLMs in mathematischen Lernumgebungen nicht allein in der Generierung korrekter Lösungen, sondern insbesondere in der Erzeugung fachlich korrekter, didaktisch angemessener und nicht lösungsverratender Hinweise. Studien zu Large Language Models im Bildungskontext betonen Risiken wie Halluzinationen, unkontrollierte Lösungsausgabe, fehlende Transparenz, unklare Verantwortlichkeit und Datenschutzprobleme.

Gleichzeitig zeigt die Forschung zu formativem Feedback, dass Rückmeldungen dann besonders lernförderlich sind, wenn sie den nächsten Denk- oder Handlungsschritt unterstützen, ohne die kognitive Aktivität der Lernenden zu ersetzen. Aus didaktischer Perspektive ist daher nicht die vollständige Lösungserzeugung das primäre Ziel, sondern die Gestaltung adaptiver Hinweise, die Lernende zur eigenständigen Weiterarbeit befähigen.

7.6 Forschungslücke

Der geplante Ansatz unterscheidet sich von bestehenden kommerziellen Systemen insofern, dass nicht das LLM die mathematische Bewertung übernehmen soll. Vielmehr bleibt STACK die mathematische Bewertungsinstanz, während das LLM auf Grundlage strukturierter Diagnosen und kuratierter Kontextinformationen adaptive Hilfen formuliert. Genau diese Kopplung von symbolischer Bewertung und generativer didaktischer Unterstützung bildet den zentralen Untersuchungsgegenstand der Arbeit.

8 Zeitplan

Ein möglicher Zeitplan für eine Bearbeitungsdauer von zwölf Wochen ist in Tabelle 8.1 dargestellt.

Bei einer längeren Bearbeitungszeit kann die Evaluation ausgeweitet werden, etwa durch zusätzliche Aufgaben, mehrere Studierende oder einen systematischeren Modellvergleich.

◀ 8 Zeitplan

Tabelle 8.1: Vorläufiger Zeitplan

Phase	Zeitraum	Inhalt
Einarbeitung und Präzisierung	Woche 1	Sichtung einschlägiger Literatur zu STACK, LLM-Tutoring, RAG und Feedback; finale Eingrenzung des Themas
Aufgaben- und Fehleranalyse	Woche 2	Auswahl der Beispielaufgabe; Analyse typischer Fehlermuster; Definition möglicher Diagnosecodes
Konzeptentwicklung	Woche 3	Entwurf der Systemarchitektur; Festlegung der Informationsübergabe; Definition des RAG-Kontexts
Implementierung des Prototyps	Woche 4–5	Entwicklung des minimalen Tutor-Interfaces; Implementierung der Übergabe von Aufgaben-ID, Antwort und Diagnose
RAG- und Promptdesign	Woche 6–7	Erstellung der Kontextdateien; Entwicklung der Promptvarianten; Definition von Hilfestufen und Tutor-Regeln
LLM-Anbindung und interne Tests	Woche 8	Anbindung eines lokalen LLMs; Durchführung erster Testläufe; Analyse der generierten Hinweise
Optimierung des Tutor-Designs	Woche 9	Anpassung der Prompts; Reduktion von Lösungsverrat; optionaler Vergleich mit einem kommerziellen Modell
Evaluation	Woche 10	Technische Evaluation; optional Durchführung einer Think-Aloud-Erprobung mit Studierenden
Auswertung	Woche 11	Auswertung der technischen und qualitativen Ergebnisse; Ableitung von Gestaltungsempfehlungen
Dokumentation und Abschluss	Woche 12	Fertigstellung der schriftlichen Ausarbeitung; Überarbeitung; finale Abgabevorbereitung

◀ 9 Vorläufige Gliederung

1. **Einleitung**

- a) Motivation
- b) Problemstellung
- c) Zielsetzung
- d) Forschungsfrage
- e) Aufbau der Arbeit

2. **Theoretische und technische Grundlagen**

- a) Moodle und STACK
- b) Potential Response Trees und mathematische Fehlerdiagnosen
- c) Large Language Models im Bildungskontext
- d) Retrieval-Augmented Generation
- e) Didaktische Anforderungen an Feedback und tutorielle Hinweise

3. **Konzeption des LLM-Tutors**

- a) Eingrenzung auf Differentialrechnung
- b) Systemarchitektur
- c) Informationsübergabe zwischen STACK und Tutor-Interface
- d) RAG-Kontext und Aufgabenmodell
- e) Prompt-Design
- f) Tutor-Policy und Hilfestufen
- g) Strategien zur Vermeidung von Lösungserrat

4. **Prototypische Implementierung**

- a) Auswahl und Umsetzung der Beispielaufgabe
- b) STACK-Feedback-Link und Parameterübergabe
- c) Tutor-Interface

◀ 9 Vorläufige Gliederung

- d) Prompt-Erzeugung
- e) LLM-Anbindung
- f) Darstellung der Tutorhinweise

5. Evaluation

- a) Evaluationsdesign
- b) Technische Evaluation
- c) Bewertung der Tutorhinweise
- d) Optionale Think-Aloud-Erprobung
- e) Auswertungskriterien

6. Ergebnisse und Diskussion

- a) Ergebnisse der technischen Umsetzung
- b) Qualität der generierten Hinweise
- c) Beobachtungen zu Lösungsverrat
- d) Nutzen des RAG-Kontexts
- e) Grenzen des Prototyps

7. Fazit und Ausblick

- a) Beantwortung der Forschungsfrage
- b) Zentrale Erkenntnisse
- c) Gestaltungsempfehlungen
- d) Ausblick auf Moodle-Integration und weitere Themenbereiche